Predicción de periodos fríos para apoyar la elaboración de chuño en Huancané

Fabricio Navarro Ureta (20220609) · Gustavo Erardo García Pulido (20227188)
Fabián Andrés Orihuela Montero (20231439) · Carlos Iván Espinoza Pulido (20232330)
Oscar Jesús Abarca Lagos (20207781)
Grupo 9 · Inteligencia Artificial 1INF24 · Horario 0782 · 2026-2

Resumen. Se evaluó la predicción de ventanas frías para apoyar la planificación de elaboración de chuño en Huancané. Utilizamos temperaturas diarias históricas y comparamos tres clasificadores y una mezcla, con selección cronológica y prueba reservada. La regresión logística seleccionada obtuvo mayor desempeño que persistencia y frecuencia mensual en la clasificación orientada a precisión. La mezcla mejoró al árbol en error probabilístico, pero no a la logística. Estos resultados apoyan la utilidad retrospectiva de la información térmica para el evento definido, con errores restantes y sin demostrar beneficios productivos ni funcionamiento operacional en parcelas.

1. Introducción

La elaboración de chuño permite conservar papa mediante congelación nocturna, descongelación diurna y deshidratación. Yoshikawa y Apaza (2020) explican que una helada ligera puede ser insuficiente para congelar el tubérculo debido al superenfriamiento. La población objetivo son las familias productoras del entorno de Huancané que procesan parte de su cosecha mediante esta práctica.

Como antecedente de su importancia productiva, el catálogo del INIA de 2009 registra entre 450 y 480 hectáreas anuales de la variedad Ocucuri Morado en Puno, destinada principalmente a tunta y chuño y cultivada también en Huancané (Palomino Flores et al. 2009: 194). En la estación de Huancané, Menacho y Dávila reportan una temperatura mínima media de −4,0 °C en invierno para 1971–2005 (2018: 75, tabla 3). En PISCOt, el 41,91 % de 5400 emisiones de entrenamiento (1981–2010) cumple la ventana definida. Su frecuencia varía entre 1,22 % en abril y 82,37 % en julio (Figura 1), lo que motiva anticipar cada secuencia. Estas cifras no dimensionan la producción total ni pérdidas de Huancané.

El problema es la incertidumbre sobre la continuidad del frío al planificar la exposición de la papa. Anticipar una secuencia permitiría añadir información térmica a la decisión de cuándo iniciar el procesamiento.

Alcance. Se desarrolló un prototipo de clasificación para una celda climática próxima a Huancané. La ventana fría se definió experimentalmente como tres días siguientes con mínimas del aire ≤ −3 °C. Se evaluó este indicador térmico, que no certifica el éxito de un lote: la temperatura interna del tubérculo, la duración del frío y las condiciones de descongelación y secado requerirían validación en campo.

Pregunta de investigación. ¿Los clasificadores entrenados con la historia térmica reciente y la estacionalidad permiten anticipar estas ventanas frías con mejor desempeño que la persistencia y la frecuencia mensual histórica en Huancané?

Hipótesis. El modelo seleccionado en validación alcanzaría un mayor puntaje $F_{0,5}$ que ambas reglas de referencia en la prueba de 2016–2020. Como hipótesis complementaria, la combinación de logística y árbol obtendría un menor puntaje de Brier que sus dos componentes en ese periodo.

Objetivo general. Desarrollar y evaluar un modelo que estime la probabilidad de la ventana térmica definida, como apoyo potencial a la planificación de la elaboración de chuño.

Objetivos específicos. Construir ejemplos supervisados y una partición cronológica; comparar los tres clasificadores y su combinación; cuantificar falsas alarmas y ventanas omitidas frente a las referencias; examinar el desempeño anual y su sensibilidad al criterio térmico.

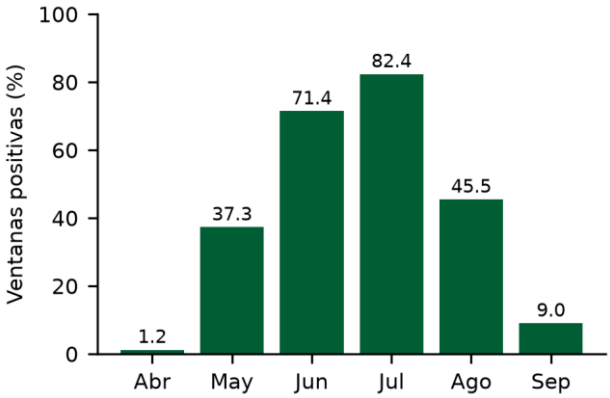


Figura 1. Ventanas positivas por mes, Huancané, entrenamiento 1981–2010. Fuente: cálculo propio sobre PISCOt; ventanas solapadas.

2. Trabajos relacionados

Yoshikawa y Apaza (2020) aportan la biofísica del superenfriamiento y comparan Huancané en 2010–2012 (figura 4). Su regla no certifica nuestra etiqueta exacta. Menacho y Dávila (2018) muestran estacionalidad y heterogeneidad en Puno; su correlación anual con ENOS no significativa al 95 % no demuestra ausencia de influencia. Estos trabajos justifican continuidad térmica y calendario, pero no evalúan nuestros clasificadores.

Huerta et al. (2023) sustentan PISCOt, reconstruido mediante control, relleno, homogeneización e interpolación. El error absoluto medio de mínima de 1,2 °C corresponde al producto original de 0,01°, no a nuestra celda de 0,10°. Los ajustes históricos y predictores satelitales de 2000–2020 limitan la interpretación operacional de la retrospectiva.

Lee et al. (2016) comparan directamente logística y árbol en seis estaciones coreanas. Usan validación dejando una observación fuera y predictores del día objetivo, incluida su mínima; advierten que pronosticar exigiría entradas meteorológicas pronosticadas. Su clasificación respalda métodos sencillos y el examen conjunto de detección y falsas alarmas, pero no demuestra anticipación a tres días.

Noh et al. (2021) estudian clasificación horaria con logística, árboles y otros modelos, con desarrollo balanceado y aleatorio y comprobaciones independientes en 2020 y huertos. La transferencia muestra que detectar heladas no asegura precisión de los avisos. La resolución horaria y las etiquetas construidas con observaciones difieren de nuestra ventana conjunta; evitamos trasladar sus métricas numéricamente.

Pérez Tárraga et al. (2025) aplican logística, vecinos y ensambles a registros diarios de estaciones españolas, con etiqueta de mínima del día siguiente inferior a cero. Su preprocesamiento y validación de diez partes difieren de nuestra separación cronológica. Su preferencia por exhaustividad responde a prevenir daño en cultivos; aquí el positivo es una oportunidad térmica para poscosecha.

Talsma et al. (2023) pronostican temperaturas horarias de Alcalde, Nuevo México, a 6–48 horas; su transferencia a Freshies requiere entrenamiento adicional. Es regresión, complementaria a los antecedentes de clasificación. Kittler et al. (1998) fundamentan explorar reglas de suma; no validan nuestra pareja logística–árbol ni garantizan su superioridad.

En conjunto, los antecedentes difieren en etiqueta, disponibilidad temporal de predictores y validación. Entre los trabajos revisados, nuestro aporte es comparar clasificadores sencillos y su mezcla para tres mínimas futuras en una celda de Huancané, con historia disponible hasta la emisión y referencias comunes. El alcance es local y retrospectivo; las diferencias de diseño impiden comparar directamente porcentajes entre países.

3. Metodología

Se extrajeron las variables tmin y tmax de los NetCDF diarios PISCOt v1.2 0,10°, celda −15,225° / −69,755°, 1981–2020. El notebook conecta Google Drive y recibe la ruta de la carpeta. Se validan nombres, dimensiones (time, latitude, longitude), unidad Celsius, malla y hashes de los dos archivos 010 antes de extraer la celda. Esta malla tiene centros separados cerca de once kilómetros.

El preprocesamiento reconstruye el calendario diario y comprueba orden temporal, duplicados, finitud y Tmín≤Tmáx. Un día inválido excluye las ventanas que lo usan en la historia o el objetivo, sin imputar etiquetas. El diagnóstico de extremos usa rangos intercuartílicos mensuales de 1981–2010 como descripción; se conservan los extremos válidos porque el frío es el fenómeno de interés. Los atributos min/max del NetCDF no se usan para recortar observaciones.

Para cada emisión t, x_t reúne siete mínimas y siete máximas desde t−6 hasta t, más $\sin(2\pi d/D)$ y $\cos(2\pi d/D)$, con d día del año y D=365 o 366. La etiqueta y_t vale 1 si las tres mínimas t+1 a t+3 son ≤−3 °C. Se estima directamente la probabilidad conjunta p_t. Las emisiones del 1 de abril al 27 de septiembre mantienen los objetivos dentro de abril–septiembre. Se simula disponer del día t completo.

Se compararon logística L2, árbol Gini y vecinos euclidianos uniformes. La logística aplica una sigmoide a una combinación lineal de atributos; el árbol divide el espacio mediante reglas y estima proporciones en sus hojas; vecinos estima la fracción positiva entre los k ejemplos más próximos. Logística y vecinos incorporan StandardScaler en sus pipelines: $z=(x-\mu)/\sigma$, con μ y σ aprendidos solo en el entrenamiento de cada etapa y reutilizados para transformar validación y prueba. El árbol se evalúa sin escalar. Se conservan las frecuencias de clase, sin remuestreo ni pesos diferenciados. Los 16 atributos están predefinidos; no se aplica reducción dimensional.

La mezcla $p^C_t=\alpha p^L_t+(1-\alpha)p^A_t$ combina una relación global con particiones locales, manteniendo un peso; vecinos permanece como comparación individual para acotar la combinación a dos componentes. Los extremos α=0 o 1 equivalen a un componente.

Persistencia asigna 1 si las mínimas de t−2 a t cumplen el umbral, y 0 de otro modo. La frecuencia mensual estima positivos por mes de emisión con etiquetas del entrenamiento. Los seis métodos comparten fechas y etiquetas.

$F_{0,5}=1,25VP/(1,25VP+FP+0,25FN)$, $P=VP/(VP+FP)$ y $R=VP/(VP+FN)$. VP y VN son aciertos positivos y negativos; FP recomienda una ventana que no cumple la etiqueta y FN omite una que sí cumple. Conservamos β=0,5 como preferencia de diseño por avisos precisos. A diferencia de F1, usado en la evaluación de Talsma, pondera más precisión (Scikit-learn developers s/f). No implica costos

económicos 4:1 ni pérdidas evitadas. Reportamos F1=2VP/(2VP+FP+FN) y una selección secundaria de umbrales por F1, definida antes de prueba, para mostrar el efecto de esta elección.

Brier=(1/n)$\Sigma(p_t-y_t)^2$ evalúa probabilidades: menor es mejor. Sin avisos, P=0; sin positivos reales, R y $F_{0,5}$ se declaran no estimables, mientras Brier sigue definido. La hipótesis principal exige diferencias puntuales positivas del modelo seleccionado frente a ambas referencias en prueba; la complementaria exige Brier de mezcla menor que ambos componentes. Los intervalos son exploratorios.

4. Experimentación y Resultados

La auditoría encontró 14 610 fechas diarias, sin duplicados, huecos, valores ausentes ni Tmín>Tmáx. No se descartaron ventanas. Entrenamiento contiene 5400 emisiones y 2263 positivos; validación, 900 y 335; prueba, 900 y 330 (36,67 %). Los episodios se definieron como rachas máximas de al menos tres días fríos dentro de abril–septiembre; las ventanas solapadas no son episodios independientes. Las emisiones empiezan con objetivos el 2 de abril, por lo que sus conteos no son intercambiables con rachas que tocan el borde.

Se eligió cada configuración por Brier medio en tres etapas: 1981–1995→1996–2000, 1981–2000→2001–2005 y 1981–2005→2006–2010. Ninguna etiqueta de entrenamiento cruza el inicio posterior. Se probaron C={0,1;1;10}, profundidad={3;5;8}, mínimo de hoja={10;30} y k={5;15;31}. Los empates numéricos (tolerancia absoluta 10^{-12}) favorecieron menor C, menor profundidad/mayor hoja o mayor k. En logística, C es el inverso de la fuerza de regularización. Se fijó semilla 2026 y logística lbfgs con hasta 10 000 iteraciones.

Las configuraciones elegidas se ajustaron con 1981–2010. En 2011–2015 se eligió $\alpha\in\{0;0,25;0,50;0,75;1\}$ por menor Brier, con mayor α en empate. Cada método probabilístico eligió τ por mayor $F_{0,5}$ entre probabilidades distintas y opción sin aviso; empate por mayor τ. Persistencia mantuvo su regla. El principal se eligió por $F_{0,5}$, después Brier y orden logística, árbol, vecinos, mezcla. Las decisiones se guardaron en freeze.json antes de ejecutar la prueba, sin reentrenar con validación.

Se repitió el protocolo para −2 y −4 °C. La variante β=1 conserva configuraciones, modelos y α, y cambia umbrales en validación; es secundaria. Se calcularon métricas globales y por año. El bootstrap usa 1000 réplicas pareadas, seis bloques móviles de treinta días calendario por cada temporada, sin cruzar años y con máscara común. Se conservaron réplicas sin positivos para Brier y se registraron las no estimables para F. Sus percentiles 2,5 y 97,5 condicionan a los modelos ya ajustados y cinco temporadas.

El experimento se reprodujo en Colab con Python 3.13.18, NumPy 2.4.6, pandas 3.1.1 y scikit-learn 1.9.1. Respecto de la ejecución local (Python 3.12.14 y NumPy 2.5.4), se conservaron decisiones y conteos, y las métricas coincidieron a la precisión reportada. Lectura y control tomaron 7,9 s; preparación, 27,2 s; prueba con bootstrap, 75,7 s en esa ejecución de Colab, excluidos montaje y copia. La auditoría de escalado verificó 96 registros de atributo y modelo, ajustados con 5400 emisiones de 1981–2010. Las salidas conservan versiones, hashes, parámetros y predicciones. PISCOt es retrospectivo: la separación temporal no prueba disponibilidad operacional histórica ni desempeño en parcelas.

La validación eligió logística C=0,1, árbol de profundidad 3 y mínimo de hoja 30, y vecinos k=31. La mezcla seleccionó α=0,75; el modelo principal fue logística, con τ=0,551970. La Tabla 1 muestra prueba, manteniendo estas decisiones. La logística obtuvo 272 VP, 75 FP y 58 FN, con precisión 0,7839 y exhaustividad 0,8242. Frente a persistencia redujo tanto FP (94→75) como FN (94→58), aunque los errores térmicos restantes siguen siendo relevantes.

Método	P	R	$F_{0,5}$	Brier
Logística	0,784	0,824	0,792	0,1124
Árbol	0,795	0,730	0,781	0,1226
Vecinos	0,773	0,724	0,763	0,1232
Mezcla	0,774	0,821	0,783	0,1130
Mensual	0,679	0,627	0,668	0,1659
Persistencia	0,715	0,715	0,715	0,2089

Tabla 1. Prueba 2016–2020, n=900, 330 positivos, umbrales fijados con validación. P=precisión; R=exhaustividad; $F_{0,5}$ mayor es mejor; Brier menor es mejor. El modelo principal es logística.

La mejora puntual en $F_{0,5}$ fue +0,0765 frente a persistencia y +0,1239 frente a frecuencia mensual, apoyando la hipótesis principal según el criterio prefijado. La Tabla 2 conserva la incertidumbre por bloques; sus intervalos no constituyen una prueba confirmatoria.

Diferencia	Punto	Lím. inf.	Lím. sup.
F: L−P	0,0765	0,0364	0,1117
F: L−M	0,1239	0,0636	0,2102
B: C−L	0,0006	-0,0011	0,0019
B: C−A	-0,0096	-0,0151	-0,0052

Tabla 2. Diferencias pareadas e intervalos percentiles exploratorios del 95 %. F compara principal menos referencia; Brier compara mezcla menos componente. L=logística; P=persistencia; M=mensual; C=mezcla; A=árbol. El signo favorable es positivo para F y negativo para Brier.

La mezcla tuvo Brier 0,113003, frente a 0,112431 de logística y 0,122625 de árbol. Mejoró al árbol, pero empeoró ligeramente a logística (+0,000572). La hipótesis complementaria no quedó apoyada. Los

avisos de logística y árbol discreparon en 56 de 900 emisiones (6,22 %): esta diferencia de decisiones no garantizó mejor probabilidad combinada.

Año	Pos.	P	R	$F_{0,5}$
2016	72	0,760	0,792	0,766
2017	62	0,875	0,903	0,881
2018	65	0,718	0,785	0,731
2019	81	0,810	0,790	0,806
2020	50	0,759	0,880	0,780

Tabla 3. Desempeño anual de la logística principal, 180 emisiones válidas por año. La comparación anual conserva el modelo y τ, sin reajustes.

Las 330 ventanas positivas de prueba corresponden a 35 rachas frías: diez en 2016, cuatro en 2017, ocho en 2018 y 2019, y cinco en 2020. El solapamiento limita la información independiente de las 900 emisiones. La variación anual debe leerse junto con la prevalencia y el tamaño de cada temporada; no se atribuye causalmente a ENOS. La Tabla 4 muestra cómo cambia la dificultad al redefinir el evento térmico.

°C	Principal	Pos.	$F_{0,5}$	Brier
-2 °C	Mezcla	422	0,8396	0,1202
-3 °C	Logística	330	0,7916	0,1124
-4 °C	Logística	255	0,6879	0,1175

Tabla 4. Sensibilidad térmica: cada definición repite ajuste y selección con el mismo protocolo. Se informa el principal elegido en su validación; −3 °C conserva el carácter de hipótesis principal.

Con los avisos principales, la logística obtuvo F1=0,8035. Al elegir su umbral por F1 en validación, pasó de τ=0,551970 a 0,436735: en prueba disminuyeron los FN de 58 a 35 y aumentaron los FP de 75 a 109, con F1=0,8038. La selección secundaria eligió la mezcla, cuyo F1 de prueba fue 0,8032 (120 FP y 28 FN). Esto muestra el compromiso entre precisión y exhaustividad sin reemplazar la hipótesis principal; las tablas completas están en el paquete reproducible. El desempeño corresponde al evento térmico de una celda, no a calidad de chuño ni beneficio económico.

5. Conclusión

La logística elegida en validación superó a ambas referencias en $F_{0,5}$ en 2016–2020, apoyando puntualmente la hipótesis principal. La mezcla no superó a la logística en Brier y la hipótesis complementaria quedó sin apoyo. La comparación retrospectiva muestra utilidad de los atributos para la etiqueta local, con errores de aviso y omisión y solo cinco temporadas de prueba. La eficacia productiva y la generalización a otras celdas requieren evaluación independiente.

6. Sugerencias de trabajos futuros

Una continuación requeriría validación temporal más reciente e independiente y mediciones de condiciones de parcelas y tubérculos. La definición experimental de ventana y la preferencia por precisión deben contrastarse con productores antes de convertirlas en una recomendación operacional. También correspondería estudiar resolución espacial y longitud de historia sin reutilizar esta prueba como conjunto de ajuste.

7. Implicancias éticas

Los FP pueden motivar exposiciones en condiciones térmicas inadecuadas; los FN omiten oportunidades potenciales. Sus consecuencias productivas no están cuantificadas. Una interfaz debería mostrar probabilidad, fecha y alcance del aviso, preservando la decisión del productor. La malla puede representar desigualmente parcelas de distinta topografía; el uso operacional requiere validación local y participación de productores. Este análisis utiliza temperaturas sin datos personales; ampliarlo con información de familias o parcelas exigiría consentimiento y protección de acceso.

8. Link del repositorio del trabajo

Repositorio privado: https://github.com/GustavoGarciaPUCP/ventana-andina-huancane . Contiene código, notebook, celda diaria, auditoría, decisiones congeladas y resultados. El propietario debe conceder lectura a los evaluadores mediante sus cuentas; no se comparten contraseñas.

9. Declaración de contribución de cada integrante

Integrante	Aportes realizados
Fabricio Navarro Ureta	_____ _____
Gustavo Erardo García Pulido	_____ _____
Fabián Andrés Orihuela Montero	_____ _____
Carlos Iván Espinoza Pulido	_____ _____
Oscar Jesús Abarca Lagos	_____ _____

10. Declaración de uso de IA

Se utilizaron ChatGPT/Codex para apoyar la revisión bibliográfica, programación, análisis y redacción, y material de Gemini revisado críticamente. Las fuentes se contrastaron y las cifras proceden de ejecutar el código con los datos identificados. La responsabilidad por la versión presentada corresponde a los autores.

11. Referencias

HUERTA, Adrian
2023 *Maximum and Minimum temperature at a coarser resolution (PISCOt v1.2)*. Versión 3 [conjunto de datos]. Figshare. Consulta: 4 de octubre de 2026. https://doi.org/10.6084/m9.figshare.22712365.v3. Archivos diarios: tmin_daily_1981_2020_010.nc y tmax_daily_1981_2020_010.nc.
Descarga de mínimas: https://ndownloader.figshare.com/files/40343728
Descarga de máximas: https://ndownloader.figshare.com/files/40343707

HUERTA, Adrian et al.
2023 "High-resolution grids of daily air temperature for Peru — the new PISCOt v1.2 dataset". *Scientific Data*. s/l, volumen 10, artículo 847. Consulta: 4 de octubre de 2026. https://doi.org/10.1038/s41597-023-02777-w

KITTLER, Josef et al.
1998 "On combining classifiers". *IEEE Transactions on Pattern Analysis and Machine Intelligence*. s/l, volumen 20, número 3, pp. 226–239. Consulta: 4 de octubre de 2026. https://doi.org/10.1109/34.667881

LEE, Hyojin et al.
2016 "Prediction of Frost Occurrences Using Statistical Modeling Approaches". Advances in Meteorology, volumen 2016, artículo 2075186. Consulta: 7 de noviembre de 2026. https://doi.org/10.1155/2016/2075186

MENACHO CASIMIRO, Ernesto y Cristina DÁVILA ARRIAGA
2018 "Influencia de el Niño-Oscilación del sur (ENOS) en la ocurrencia de heladas en el altiplano peruano". *Anales Científicos*. Lima, volumen 79, número 1, pp. 70–80. Consulta: 4 de octubre de 2026. https://doi.org/10.21704/ac.v79i1.1142

NOH, I. et al.
2021 "Machine Learning-Based Hourly Frost-Prediction System Optimized for Orchards Using Automatic Weather Station and Digital Camera Image Data". Atmosphere, volumen 12, número 7, artículo 846. Consulta: 7 de noviembre de 2026. https://doi.org/10.3390/atmos12070846

PALOMINO FLORES, Ladislao et al.
2009 *Caracterización morfológica y agronómica de 61 variedades nativas de papa*. s/l: Instituto Nacional de Innovación Agraria. Consulta: 4 de octubre de 2026. https://repositorio.inia.gob.pe/handle/20.500.12955/86

PÉREZ TÁRRAGA, J. et al.
2025 "Frost forecasting through machine learning algorithms". Earth Science Informatics, volumen 18, artículo 183. Consulta: 7 de noviembre de 2026. https://doi.org/10.1007/s12145-025-01710-6

SCIKIT-LEARN DEVELOPERS
s/f "fbeta_score". Documentación oficial. Consulta: 7 de noviembre de 2026. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.fbeta_score.html

TALSMA, Carl J. et al.
2023 "Frost prediction using machine learning and deep neural network models". *Frontiers in Artificial Intelligence*. s/l, volumen 5 (2022), artículo 963781. Publicado el 12 de enero de 2023. Consulta: 4 de octubre de 2026. https://doi.org/10.3389/frai.2022.963781

YOSHIKAWA, Kenji y Fredy APAZA
2020 "Unfrozen state by the supercooling of chuño for traditional agriculture in altiplano andes". *Environmental and Sustainability Indicators*. s/l, volumen 8, artículo 100063. Consulta: 4 de octubre de 2026. https://doi.org/10.1016/j.indic.2020.100063